



3η Προγραμματιστική Εργασία

-

Αναζήτηση Απομακρυσμένων ομόλογων με Προσεγγιστικές Μεθόδους ESM

Ονοματεπώνυμο: Παπαθανασίου Ελένη

A.M.: 1115202200135

Ονοματεπώνυμο: Τόντου Αλτάνη-Δάφνη

A.M.: 1115202200288

1 Εισαγωγή

Σκοπός της εργασίας ήταν η συγκριτική αξιολόγηση διαφορετικών προσεγγιστικών μεθόδων αναζήτησης πλησιέστερων γειτόνων για τον εντοπισμό απομακρυσμένων ομόλογων (remote homologs) πρωτεϊνών, με βάση διανυσματικές αναπαραστάσεις (embeddings) που παράχθηκαν από το μοντέλο ESM-2. Οι μέθοδοι που εξετάστηκαν είναι οι εξής: Euclidean LSH, Hypercube Projection, IVF-Flat, IVFPQ και Neural LSH. Για κάθε μέθοδο διερευνήθηκαν διάφορες υπερ-παράμετροι και μετρήθηκαν ο χρόνος αναζήτησης, το QPS και η μετρική Recall@N συγκριτικά με τα αποτελέσματα του Blast.

2 Αποτελέσματα

Number	k	L	w	seed
1	4	30	15	42
2	6	20	10	42
3	6	40	20	42
4	8	15	8	42
5	10	10	6	42
6	10	10	8	42
7	10	25	12	42

Πίνακας 1: Παράμετροι μοντέλου LSH

Number	Μέσος Χρόνος Αναζήτησης	Μέσος QPS	Μέσος Recall@50
1	0.1962s	5.2	0.318
2	0.1731s	5.9	0.318
3	0.1833s	5.6	0.318
4	0.2342s	4.7	0.318
5	0.0746s	17.3	0.320
6	0.1255s	5.6	0.318
7	0.1825s	5.6	0.318

Πίνακας 2: Αποτελέσματα αναζήτησης LSH

Number	k	M	p	w	seed
1	8	1500	8	6	42
2	10	1000	5	4	42
3	10	1000	5	8	42
4	10	1000	10	4	42
5	10	5000	5	4	42
6	12	2500	12	5	42
7	16	3500	16	3	42

Πίνακας 3: Παράμετροι μοντέλου Hypercube

Number	Μέσος Χρόνος Αναζήτησης	Μέσος QPS	Μέσος Recall@50
1	0.0068s	153.9	0.163
2	0.0013s	1718.7	0.038
3	0.0050s	214.5	0.066
4	0.0026s	692.3	0.095
5	0.0017s	1408.0	0.041
6	0.0030s	515.3	0.089
7	0.0130s	8820.9	0.030

Πίνακας 4: Αποτελέσματα αναζήτησης Hypercube

Number	nlist	nprobe
1	50	5
2	50	20
3	200	10
4	150	15
5	200	50
6	100	5

Πίνακας 5: Παράμετροι μοντέλου IVFFlat

Number	Μέσος Χρόνος Αναζήτησης	Μέσος QPS	Μέσος Recall@50
1	3.7627s	51.4	0.278
2	5.0295s	11.7	0.318
3	19.2361s	92.7	0.304
4	15.1047s	51.8	0.318
5	20.5713s	24.4	0.318
6	8.2772s	83.1	0.286

Πίνακας 6: Αποτελέσματα αναζήτησης IVFFlat

Number	nlist	nprobe	m
1	200	100	8
2	100	25	8
3	50	10	8
4	100	25	32
5	100	25	4
6	100	25	16
7	400	200	8

Πίνακας 7: Παράμετροι μοντέλου IVFPQ

Number	Μέσος Χρόνος Αναζήτησης	Μέσος QPS	Μέσος Recall@50
1	0.9801s	1.0	0.260
2	0.3017s	3.4	0.267
3	0.1301s	7.9	0.264
4	1.1317s	0.9	0.272
5	0.1657s	6.3	0.251
6	0.6088s	1.7	0.297
7	2.2599s	0.4	0.274

Πίνακας 8: Αποτελέσματα αναζήτησης IVFPQ

Number	k	m	T	epochs
1	10	100	5	10
2	20	100	5	10
3	10	200	5	10
4	10	100	15	10
5	10	100	5	20
6	15	150	10	15
7	25	250	20	25

Πίνακας 9: Παράμετροι μοντέλου Neural LSH

Number	Μέσος Χρόνος Αναζήτησης	Μέσος QPS	Μέσος Recall@50
1	0.0048s	228.7	0.293
2	0.0048s	238.6	0.293
3	0.0027s	401.1	0.238
4	0.0162s	74.5	0.310
5	0.0038s	306.9	0.270
6	0.0050s	209.3	0.271
7	0.0051s	209.6	0.310

Πίνακας 10: Αποτελέσματα αναζήτησης Neural LSH

3 Σύγκριση Αποτελεσμάτων

3.1 Συγκρίσεις Μεθόδων Ανά Ζεύγη

3.1.1 Hypercube και Neural LSH

- Ταχύτητα: Το Hypercube (μέγιστο QPS 1718.7) είναι σχεδόν 8 φορές ταχύτερο από το Neural LSH (μέγιστο QPS 209.6).
- Ακρίβεια: Το Neural LSH (Recall 0.310) είναι σχεδόν διπλάσιο σε ακρίβεια από το Hypercube (Recall 0.163).
- Συμπέρασμα: Για γρήγορο προκαταρκτικό φιλτράρισμα επιλέγουμε Hypercube, ενώ για ισορροπημένη απόδοση Neural LSH.

3.1.2 Euclidean LSH και IVF-Flat

- Ταχύτητα: Το Euclidean LSH (QPS 17.3) είναι 3 φορές ταχύτερο από το IVF-Flat (QPS 51.8).
- Ακρίβεια: Πολύ παρόμοια (Euclidean LSH: 0.320, IVF-Flat: 0.318) - διαφορά μόνο 0.6%.
- Συμπέρασμα: Το Euclidean LSH υπερτερεί καθώς προσφέρει ίδια ακρίβεια με μεγαλύτερη ταχύτητα.

3.1.3 IVF-Flat και IVFPQ

- Ταχύτητα: Το IVFPQ (QPS 181.0) είναι 3.5 φορές ταχύτερο από το IVF-Flat (QPS 51.8).
- Ακρίβεια: Το IVF-Flat (0.318) είναι 22% πιο ακριβές από το IVFPQ (0.260).
- Συμπέρασμα: Το IVFPQ θυσιάζει λίγη ακρίβεια για σημαντικά μεγαλύτερη ταχύτητα.

3.1.4 Neural LSH και Euclidean LSH

- Ταχύτητα: Το Neural LSH (QPS 74.5) είναι 4.3 φορές ταχύτερο από το Euclidean LSH (QPS 17.3).
- Ακρίβεια: Το Euclidean LSH (0.320) είναι 3.2% πιο ακριβές από το Neural LSH (0.310).
- Συμπέρασμα: Το Neural LSH προσφέρει καλύτερο συμβιβασμό ταχύτητας-ακρίβειας.

3.1.5 IVFPQ και Hypercube

- Ταχύτητα: Το Hypercube (QPS 153.9) είναι 17% πιο γρήγορο από το IVFPQ (QPS 181.0).
- Ακρίβεια: Το IVFPQ (Recall 0.260) είναι 60% πιο ακριβές από το Hypercube (Recall 0.163).
- Συμπέρασμα: Το IVFPQ υπερτερεί καθώς προσφέρει σημαντικά καλύτερη ακρίβεια με ελάχιστη μείωση ταχύτητας.

3.1.6 Neural LSH και IVFPQ

- Ταχύτητα: Το IVFPQ (QPS 181.0) είναι 2.4 φορές ταχύτερο από το Neural LSH (QPS 74.5).
- Ακρίβεια: Το Neural LSH (0.310) είναι 19% πιο ακριβές από το IVFPQ (0.260).
- Συμπέρασμα: Το Neural LSH είναι καλύτερο για ακρίβεια, το IVFPQ για ταχύτητα.

3.2 Βέλτιστη Επιλογή ανά Σενάριο

1. Για γρήγορη προκαταρκτική αναζήτηση: Hypercube (υψηλό QPS, χαμηλό Recall).
2. Για ισορροπημένη απόδοση σε πραγματικό χρόνο: Neural LSH (καλό QPS, καλό Recall).
3. Για μεγάλα δεδομένα με περιορισμένη μνήμη: IVFPQ (υψηλό QPS, μέτριο Recall).
4. Για μέγιστη ακρίβεια (offline): Euclidean LSH (μέτριο QPS, υψηλό Recall).
5. Για μέγιστη ακρίβεια ανεξάρτητα χρόνου: IVF-Flat (χαμηλό QPS, υψηλό Recall).

3.3 Συνολική Ταξινόμηση

- Από ταχύτερη προς αργότερη:
 1. Hypercube (153.9 QPS)
 2. IVFPQ (181.0 QPS)
 3. Neural LSH (74.5 QPS)
 4. Euclidean LSH (17.3 QPS)
 5. IVF-Flat (51.8 QPS)
- Από ακριβέστερη προς λιγότερο ακριβή:
 1. Euclidean LSH (0.320 Recall)
 2. IVF-Flat (0.318 Recall)
 3. Neural LSH (0.310 Recall)
 4. IVFPQ (0.260 Recall)
 5. Hypercube (0.163 Recall)

3.4 Συμπεράσματα Συγκριτικής Ανάλυσης

1. Υπάρχει σαφές trade-off ταχύτητας-ακρίβειας: Ταχύτερες μέθοδοι έχουν χαμηλότερη ακρίβεια και αντίστροφα.
2. Το Neural LSH είναι η πιο ισορροπημένη μέθοδος, καταλαμβάνοντας τη 3η θέση σε ταχύτητα και την 3η θέση σε ακρίβεια.
3. Το IVFPQ προσφέρει το καλύτερο value για εφαρμογές που χρειάζονται ταχύτητα χωρίς υπερβολική θυσία ακρίβειας.
4. Το Euclidean LSH παραμένει η καλύτερη επιλογή όταν η ακρίβεια είναι η απόλυτη προτεραιότητα.
5. Το Hypercube, παρότι πολύ ταχύ, έχει περιορισμένη χρησιμότητα λόγω της χαμηλής του ακρίβειας σε βιολογικά δεδομένα.

4 Ορισμός Remote Homolog

Remote Homolog ορίζεται ως πρωτεΐνη που:

- Έχει ομοιότητα ακολουθίας (BLAST identity) $< 30\%$ (Twilight Zone)
- Εμφανίζει μικρή L2 απόσταση στον χώρο embeddings (Top-N γείτονες σε μια ή περισσότερες μεθόδους ANN).
- Διατηρεί παρόμοια βιολογική λειτουργία ή δομικά domains, όπως τεκμηριώνεται από τις βάσεις δεδομένων (UniProt, Pfam, GO).

4.1 Χαρακτηριστικά Παραδείγματα

Παρακάτω παρουσιάζουμε 3 υποθετικά παραδείγματα που εξηγούν πώς οι embedding-based μέθοδοι εντοπίζουν υποψήφια απομακρυσμένες ομόλογες πρωτεΐνες που δεν ανιχνεύονται από το BLAST.

Παράδειγμα 1: Πρωτεΐνη A0A009I3Y5

- Μέθοδος: Euclidean LSH (από results_lsh_k6_L20_w10.txt)
- Περιγραφή: Για αυτή την πρωτεΐνη-στόχο, και οι 10 πρώτοι γείτονες που επιστρέφει το ΛΣΗ έχουν 0.0% BLAST identity και δεν ανήκουν στο Top-N του BLAST.
- Επιλεγμένος γείτονας: sp|P14181|LICA2_HAEIF (L2 απόσταση = 1.685)
- Σχολιασμός
 - Η LICA2_HAEIF αντιστοιχεί σε μια λιγάση του *Haemophilus influenzae* (σύμφωνα με το UniProt).
 - Το γεγονός ότι η απόσταση L2 είναι σχετικά μικρή (1.685) σε σχέση με άλλες βάσεις δεδομένων, ενώ η ακολουθιακή ομολογία είναι μηδενική, υποδηλώνει ότι το embedding έχει μάθει κάποια δομική ή λειτουργική ομοιότητα που δεν ανιχνεύεται από το BLAST.
 - Μπορεί να πρόκειται για απομακρυσμένη ομόλογη που διατηρεί ένα κρίσιμο domain (π.χ., ένα domain συντηρημένο σε επίπεδο τριτοταγούς δομής) που το embedding μπορεί να έχει καταγράψει.

Παράδειγμα 2: Πρωτεΐνη A0A009PCK4

- Μέθοδος: Euclidean LSH (από results_lsh_k6_L20_w10.txt)
- Περιγραφή: Στην ίδια λίστα με το προηγούμενο παράδειγμα, ο 7ος γείτονας (sp|P24362|KRB2_VACCV) έχει 27.0% BLAST identity και ανήκει στο BLAST Top-N, ενώ οι υπόλοιποι 9 έχουν 0.0% και δεν ανήκουν.
- Επιλεγμένος γείτονας: sp|P14181|LICA2_HAEIF (L2 απόσταση = 1.670) πάλι με 0.0% BLAST identity.
- Σχολιασμός
 - Το LSH επιστρέφει ταυτόχρονα γνωστές ομολογίες (με BLAST) και υποψήφια απομακρυσμένες. Αυτό δείχνει ότι το embedding space μπορεί να διατηρεί τόσο τις εύκολες ομολογίες όσο και να προτείνει νέες υποψήφιας.

- Η LICA2_HAEIF εμφανίζεται και εδώ ως κοντινός γείτονας, υποστηρίζοντας την υπόθεση ότι υπάρχει μια συστηματική σχέση μεταξύ αυτής της οικογένειας πρωτεϊνών και της query, η οποία δεν είναι εμφανής ακολουθιακά.

Παράδειγμα 3: Πρωτεΐνη A0A009HPM0

- Μέθοδος: VF-PQ (από ivfpq_balanced_100_25_8.txt)
- Περιγραφή: Για αυτή την χυερψ, όλοι οι top-10 γείτονες έχουν 0.0% BLAST identity και το πεδίο “Bio comment” αναφέρει “No BLAST match”.
- Επιλεγμένος γείτονας: sp|Q612F5|PCCA_CAEBR (L2 απόσταση = 1.270) πάλι με 40.7% BLAST identity και είναι στο BLAST Top-N (αυτή είναι μια εξαίρεση, αλλά οι υπόλοιποι 9 είναι “No BLAST match”).
- Σχολιασμός
 - Το γεγονός ότι το IVF-PQ επιστρέφει μια λίστα με πρωτεΐνες που δεν ταυτίζονται με BLAST (εκτός από μία) δείχνει ότι η μέθοδος μπορεί να προωθήσει εντελώς νέες υποψήφιας για βιολογική επικύρωση.
 - Πιθανόν οι ενσωματωμένες αναπαραστάσεις να έχουν μάθει λειτουργικά σημαντικά μοτίβα που είναι κοινά σε αυτές τις πρωτεΐνες, αλλά η ακολουθιακή τους απόσταση είναι πολύ μεγάλη για να ανιχνευθεί με BLAST.

Παράδειγμα 4: Πρωτεΐνη A0A010Q8R4

- Μέθοδος: VF-PQ (από ivfpq_balanced_50_10_8.txt)
- Περιγραφή: Αυτή η query έχει Recall@50 = 0.500, δηλαδή το embedding βρίσκει το μισό από τα αληθινά θετικά του BLAST. Παράλληλα, πολλοί από τους κοντινούς γείτονες έχουν 0.0% BLAST identity.
- Επιλεγμένος γείτονας: sp|P0CS29|ATG18_CRYNB (L2 απόσταση = 1.356)- “No BLAST match”.
- Σχολιασμός
 - Η ύπαρξη υψηλού recall μαζί με πολλών μη ταυτισμένων γειτόνων υποδηλώνει ότι το embedding μπορεί να καλύπτει ένα ευρύτερο φάσμα ομολογίας από το BLAST.
 - Η πρωτεΐνη ATG18_CRYNB σχετίζεται με την αυτοφαγία (Autophagy-related protein 18). Αν η query ανήκει σε παρόμοιο μονοπάτι, το embedding ίσως έχει ανακαλύψει μια λειτουργική σύνδεση που δεν φαίνεται στην ακολουθία.

4.1.1 Σχολιασμός

Τα παραδείγματα που παρουσιάστηκαν δείχνουν ότι οι μέθοδοι που βασίζονται σε embeddings μπορούν να εντοπίσουν σχέσεις μεταξύ πρωτεϊνών που δεν είναι εμφανείς με βάση μόνο την ακολουθία. Το BLAST αποτυγχάνει συχνά όταν η ομοιότητα ακολουθίας είναι πολύ χαμηλή, ενώ τα ESM-2 embeddings φαίνεται να διατηρούν πληροφορία που σχετίζεται με τη δομή ή τη λειτουργία των πρωτεϊνών.

Σε αρκετές περιπτώσεις, πρωτεΐνες με 0% BLAST identity εμφανίζονται πολύ κοντά στον χώρο των διανυσμάτων, αυτό δείχνει πιθανή απομακρυσμένη ομολογία. Η επανεμφάνιση συγκεκριμένων πρωτεϊνών ως κοντινών γειτόνων σε διαφορετικά queries ενισχύει αυτή την υπόθεση.

Παράλληλα, παρατηρούνται και περιπτώσεις όπου μικρή L2 απόσταση δεν συνοδεύεται από ξεκάθαρη βιολογική σχέση. Αυτό δείχνει ότι υπάρχουν και false positives, και επομένως τα αποτελέσματα των ANN μεθόδων πρέπει να αξιολογούνται προσεκτικά και σε συνδυασμό με βιολογική πληροφορία.

5 Συζήτηση Ορίων και Προτεινόμενες Βελτιώσεις

5.1 Περιορισμοί

Ένας βασικός περιορισμός της προσέγγισης είναι ότι η ποιότητα των αποτελεσμάτων εξαρτάται άμεσα από τα embeddings. Αν και το ESM-2 είναι ένα ισχυρό μοντέλο, δεν είναι ειδικά εκπαιδευμένο για την ανίχνευση απομακρυσμένων ομολογων πρωτεϊνών.

Επιπλέον, όλες οι προσεγγιστικές μέθοδοι παρουσιάζουν έναν συμβιβασμό μεταξύ ταχύτητας και ακρίβειας. Μέθοδοι με πολύ υψηλό QPS, όπως το Hypercube, είναι πολύ γρήγορες αλλά εμφανίζουν χαμηλό Recall, κάτι που περιορίζει τη χρησιμότητά τους σε βιολογικές εφαρμογές.

Τέλος, το BLAST χρησιμοποιείται ως μέτρο σύγκρισης, παρότι είναι γνωστό ότι δεν ανιχνεύει όλες τις απομακρυσμένες ομολογίες. Αυτό σημαίνει ότι το Recall@N μπορεί να υποεκτιμά πραγματικές βιολογικές σχέσεις.

5.2 Προτάσεις Βελτίωσης

Μια πιθανή βελτίωση είναι η χρήση μεγαλύτερων ή πιο εξειδικευμένων μοντέλων protein embeddings, τα οποία θα μπορούσαν να αποτυπώνουν καλύτερα λειτουργικές και δομικές ομοιότητες.

Επιπλέον, η αξιοποίηση πρόσθετης βιολογικής πληροφορίας, όπως Pfam domains, GO όροι ή δεδομένα δομής, θα μπορούσε να βοηθήσει στη μείωση των false positives.

Τέλος, ένας συνδυασμός μεθόδων, όπου οι προσεγγιστικές τεχνικές χρησιμοποιούνται για γρήγορο φιλτράρισμα και ακολουθεί πιο ακριβής ανάλυση, θα μπορούσε να βελτιώσει τη συνολική απόδοση του συστήματος.

6 Συμπερασμα

Στην εργασία αυτή συγκρίθηκαν διάφορες προσεγγιστικές μέθοδοι αναζήτησης πλησιέστερων γειτόνων για τον εντοπισμό απομακρυσμένων ομολογων πρωτεϊνών, χρησιμοποιώντας embeddings από το μοντέλο ESM-2.

Τα αποτελέσματα έδειξαν ότι οι embedding-based μέθοδοι μπορούν να εντοπίσουν πιθανές ομολογίες που δεν ανιχνεύονται από το BLAST, ειδικά σε περιπτώσεις χαμηλής ομοιότητας ακολουθίας. Το Neural LSH παρουσίασε την πιο ισορροπημένη σχέση ταχύτητας και ακρίβειας, ενώ το IVFPQ ήταν ιδιαίτερα αποδοτικό σε σενάρια όπου η ταχύτητα είναι κρίσιμη.

Συνολικά, η εργασία δείχνει ότι ο συνδυασμός σύγχρονων protein language models και αποδοτικών μεθόδων ANN αποτελεί ένα χρήσιμο εργαλείο για τη μελέτη απομακρυσμένων ομολογων πρωτεϊνών.